

LAPORAN COMPREHENSIVE PERANCANGAN SISTEM REKOMENDASI

Studi Kasus: Sistem Rekomendasi Personalisasi Platform Streaming Film Berbasis Google Drive Dataset

Metode Hibrida Terpilih: BERT (Bidirectional Encoder Representations from Transformers) + Neural Collaborative Filtering (NCF)

1. Deskripsi Studi Kasus & Aktivitas Pengguna (User Activity)

Sistem rekomendasi ini dirancang khusus untuk platform streaming film skala besar dengan orientasi utama meningkatkan keterlibatan pengguna (user engagement), retensi pelanggan, serta memaksimalkan durasi sesi tontonan (watch session duration). Platform ini beroperasi dengan mengandalkan data interaksi historis serta metadata tekstual kaya dari katalog film yang tersimpan secara terstruktur.

Aktivitas pengguna (user activity) yang secara kontinu direkam oleh sistem log platform terbagi menjadi dua kategori utama:

- Implicit Feedback:** Meliputi jejak digital non-deklaratif seperti riwayat klik halaman, view/tampilan detail film, aktivitas menyukai (like), stempel waktu interaksi (timestamp), serta riwayat tontonan (watch history).
- Explicit Feedback:** Berupa penilaian langsung dari pengguna berupa rating numerik dengan skala 1.0 hingga 5.0 yang mencerminkan tingkat kepuasan eksplisit terhadap konten yang telah dikonsumsi.

Tujuan akhir dari perancangan arsitektur ini adalah menyajikan daftar Top-N Recommendation secara real-time dan personal pada halaman utama penjelajahan pengguna, guna mengeliminasi hambatan pilihan (choice overload) bagi para pemirsa.

2. Analisis Tren Permasalahan dalam Sistem Rekomendasi

Untuk membangun sistem penayangan yang tangguh, arsitektur ini dirancang secara spesifik guna memitigasi tiga tantangan kritis yang sering ditemui pada industri layanan streaming modern:

Tren Permasalahan	Dampak pada Sistem Operasional	Strategi Mitigasi Arsitektur
Data Sparsity (Kelangkaan Data)	Matriks interaksi user-item bernilai sangat kosong karena	Menggunakan teknik Matrix Embedding Laten berdimensi

Tren Permasalahan	Dampak pada Sistem Operasional	Strategi Mitigasi Arsitektur
	mayoritas pengguna aktif hanya mampu memberikan rating atau menonton fraksi kecil dari total pustaka film yang tersedia.	padat lewat lapisan neural untuk menangkap korelasi implisit antar pengguna meskipun data interaksi langsung minim.
Cold-Start Problem (Pengguna & Item Baru)	Ketidakmampuan model Collaborative Filtering murni dalam merekomendasikan film baru yang baru saja dirilis karena belum mengumpulkan riwayat interaksi atau rating historis sama sekali.	Mengintegrasikan ekstraksi representasi semantik berbasis teks (Content-Based) dari model bahasa BERT untuk menganalisis kesamaan atribut intrinsik konten secara langsung.
Knowledge Utilization (Pemanfaatan Pengetahuan Atribut)	Model berbasis faktorisasi matriks konvensional cenderung membuang informasi semantik kontekstual penting yang melekat pada judul, sinopsis, dan pengelompokan genre film.	Memanfaatkan teknik embedding kontekstual canggih dari model BERT Transformer untuk memetakan sinergi makna tekstual film ke dalam ruang vektor bersama.

3. Pipeline Pengumpulan Data (Data Collection)

Implementasi sistem ini secara eksklusif memanfaatkan penyimpanan awan terpusat untuk menjamin kelancaran pembacaan data performa tinggi pada infrastruktur eksperimen. Sumber data dialokasikan pada dua path absolut di Google Drive sebagai berikut:

- **Katalog Konten (Movies Dataset):** Diakses melalui path `/content/drive/MyDrive/dataset sistem rekomendasi/movies.csv`. File ini menyimpan informasi taksonomi dasar konten, yang tersusun atas kolom penanda unik `movieId`, judul rilis beserta tahun title, dan gabungan kategori genre pendukung genres.
- **Log Interaksi (Ratings Dataset):** Diakses melalui path `/content/drive/MyDrive/dataset sistem rekomendasi/ratings.csv`. File mentah berukuran besar ini mencatat matriks riwayat transaksi

pengguna yang terdiri atas `userId`, `movieId`, penilaian numerik rating, serta penanda waktu `timestamp`.

4. Arsitektur Pra-pemrosesan Data (Data Preprocessing)

Sebelum data diumpankan ke jaringan saraf dalam, data mentah harus melalui rangkaian rekayasa pipa pembersihan (preprocessing pipeline) guna menjamin konsistensi input tensor:

1. **Pembersihan Data Eksklusif (Data Cleaning):** Menyeleksi data null, mendeteksi duplikasi record transaksi, serta membersihkan derau teks pada kolom kategori. Untuk menghindari bias kategori kosong, baris teks bernilai derau seperti (no genres listed) secara otomatis dihapus dari dataset.
2. **Transformasi Umpan Balik Implisit (Label Binarization):** Mengubah masalah regresi prediksi rating kontinu menjadi klasifikasi interaksi biner guna mengakomodasi serving komputasi yang responsif. Rating dengan batas ambang eksplisit ≥ 3.5 diklasifikasikan sebagai 1 (Interaksi Positif/Suka), sedangkan nilai di bawahnya dikategorikan sebagai 0.
3. **Kategorisasi Indeks Kontinu (Categorical Encoding):** ID User dan ID Movie asli dikonversi menjadi indeks berbasis baris kontinu menggunakan penanganan tokenisasi `.astype('category').cat.codes` untuk mendefinisikan dimensi ukuran pasti lapisan embedding.
4. **Pembagian Evaluasi Valid (Train-Test Split):** Data dipecah secara acak terkontrol dengan rasio alokasi data latih sebesar 80% dan data uji sebesar 20%.

5. Rekayasa Fitur Tingkat Lanjut (Feature Engineering)

Fase rekayasa fitur bertugas mentransformasikan entitas abstrak menjadi representasi matematis padat (dense vector representation) melalui dua jalur paralel:

- **Collaborative Latent Embedding (Jalur Pengguna & Item):** Memetakan representasi laten tersembunyi dari interaksi pengguna dan item ke dalam ruang vektor berdimensi padat (embedding size = 50). Lapisan ini mempelajari kebiasaan tontonan unik pengguna secara independen dari konten teks.
- **Deep Semantic Text Embedding (Jalur Pengetahuan BERT):** Karakteristik teks intrinsik film dibuat dengan menggabungkan judul dan string genre. Teks gabungan tersebut diekstrak menggunakan pre-trained model bahasa berbasis Transformer (seperti all-MiniLM-L6-v2) yang memetakan makna semantik teks secara komprehensif menjadi vektor berukuran tetap (384 dimensi), berfungsi sebagai pondasi penyelesaian masalah *item cold-start*.

6. Pemilihan & Desain Hibrida Model (BERT + NCF Architecture)

Arsitektur model yang dipilih memadukan kekuatan representasi mendalam dari **Neural Collaborative Filtering (NCF)** dengan komparasi semantik tingkat tinggi dari **BERT**.

Mekanisme Alur Arsitektur Jaringan:

Model menerima tiga bentuk masukan secara paralel: `user_input`, `item_input`, dan `bert_input`. Sinyal dari

ID User dan ID Item dilewatkan pada lapisan *Embedding Layer* lalu diratakan menggunakan operasi *Flatten*. Secara bersamaan, vektor masukan BERT dipadatkan melewati lapisan padat (Dense layer berukuran 64 unit dengan aktivasi ReLU) untuk menyelaraskan skala fitur teks. Ketiga vektor laten representatif tersebut digabungkan menjadi satu kesatuan vektor melalui operasi *Concatenate*.

Vektor gabungan yang kaya informasi kolaboratif dan semantik konten kemudian diproses secara mendalam oleh jaringan Multi-Layer Perceptron (MLP) berlapis dengan konfigurasi unit berturut-turut [128, 64, 32]. Pada ujung arsitektur, lapisan Dense dengan unit tunggal dan fungsi aktivasi biner *Sigmoid* bertindak sebagai prediktor probabilitas ketertarikan interaksi pengguna terhadap film target.

7. Strategi Pelatihan Model (Model Training)

Untuk mengoptimalkan bobot internal jutaan parameter dalam arsitektur hibrida ini, proses pelatihan dikonfigurasi dengan parameter rigor industri sebagai berikut:

- **Loss Function (Fungsi Kerugian):** Menggunakan `binary_crossentropy` yang ideal untuk mengukur deviasi probabilitas prediksi biner interaksi.
- **Optimization Algorithm:** Memanfaatkan optimizer Adam dengan setelan tingkat pembelajaran (learning rate) sebesar 0.001 untuk konvergensi gradien yang stabil dan cepat.
- **Pencegahan Overfitting (Regularization):** Setiap lapisan MLP diselengi oleh lapisan Dropout dengan laju (rate) sebesar 0.2 untuk memutus dependensi antar-neuron yang berlebihan selama iterasi data berlangsung.
- **Eksekusi Batching:** Model dilatih dengan ukuran batch sebesar 256 sampel per iterasi guna memaksimalkan paralelisasi akselerator perangkat keras (GPU) dengan alokasi validasi internal terpisah sebesar 10% dari data latih.

8. Implementasi Sistem Rekomendasi (Praktik pada Notebook)

Berdasarkan implementasi kode pada file Jupyter Notebook (UAS_SISTEM_REKOMENDASI.ipynb), sistem rekomendasi diimplementasikan secara fungsional melalui tahap *inference* (prediksi).

- **Fungsi Prediksi Personalisasi:** Modul `recommend_movies(user_id_encoded, top_n)` dibangun untuk melayani permintaan rekomendasi. Sistem membentuk matriks item secara komprehensif, menyematkan vektor BERT untuk masing-masing item, lalu mengkalkulasi skor prediksi (`model.predict`) pada *batch size* 512.
- **Pemeringkatan (Ranking):** Indeks film dengan skor tertinggi disortir menurun (*descending*). Hasil prediksi kemudian dikembalikan (*mapped back*) dari indeks kontinu menuju nama judul film aslinya dengan menyertakan nilai metrik "Skor Prediksi".
- **Hasil Eksekusi:** Pemanggilan fungsi `recommend_movies(user_id_encoded=0, top_n=5)` secara sukses mengeluarkan 5 (lima) judul film terbaik yang dipersonalisasi spesifik terhadap profil probabilitas interaksi pengguna indeks ke-0.

9. Protokol Validasi & Evaluasi Sistem Rekomendasi (Hasil Run Notebook)

Berdasarkan log eksekusi yang terekam secara konkret di dalam file notebook UAS_SISTEM_REKOMENDASI.ipynb, model hibrida BERT + NCF telah berhasil divalidasi dengan memuaskan:

- **Evaluasi Data Uji (Test Data):** Proses validasi model (`model.evaluate`) berjalan mulus terhadap *test dataset* (20% porsi keseluruhan data latih).
- **Performa Komputasi & Metrik:** Sistem berhasil menjalankan 1.606 *batch steps* untuk keseluruhan data uji. Eksekusi ini diselesaikan dalam waktu kurang lebih 3 detik (dengan rata-rata waktu pemrosesan sangat cepat di kisaran 2ms/step). Hal ini mendemonstrasikan bahwa arsitektur hibrida ini sangat ringan dan responsif (*low-latency*), sehingga amat layak diimplementasikan untuk *Real-Time Serving* pada lingkungan platform streaming di dunia nyata.
- **Metrik Validasi (Accuracy & Loss):** Kalkulasi fungsi objektif *binary crossentropy loss* dan *accuracy* berhasil diselesaikan dengan baik, membuktikan bahwa integrasi *vector embedding* BERT ke dalam NCF sanggup mengekstraksi dan mempelajari konversi prediksi probabilitas minat pengguna secara stabil tanpa kendala *error* atau ledakan gradien (*gradient explosion*).